TP — Projet Cloud Smart City

Fait par :

François NGY

Antoine THEISSEN

Rick Georges YELEUMEU VOGMO

Introduction

Le projet Smart City vise à aider l'utilisateur à choisir le moyen de transport le plus efficace en milieu urbain. Pour cela, il exploite plusieurs sources de données ouvertes : disponibilité Vélib, trafic routier, transports en commun et qualité de l'air.

Cartographie du projet cloud et des données

Présentation synthétique de l'existant

L'architecture du projet repose sur une collecte de données externes depuis des API Paris Data et un fichier CSV. Ces données sont récupérées par des fonctions Lambda, stockées dans Amazon S3, puis traitées avant d'être exploitées dans DynamoDB et exposées à l'application via un backend et API Gateway.

Sources de données identifiées

- API Vélib
- API voitures / trafic routier
- API transport en commun
- Fichier CSV qualité de l'air

Types de données manipulées

- Données structurées JSON provenant des API.
- Données structurées CSV pour la qualité de l'air.
- Données transformées et nettoyées en Parquet dans S3.
- Données métier agrégées et exposées via DynamoDB pour l'application.

Données sensibles ou non

Les données utilisées sont principalement publiques et non personnelles. Le risque principal n'est donc pas la confidentialité forte, mais surtout l'intégrité, la disponibilité, la qualité et la traçabilité. Une donnée erronée peut conduire à une mauvaise recommandation de transport.

Schéma d’architecture proposé

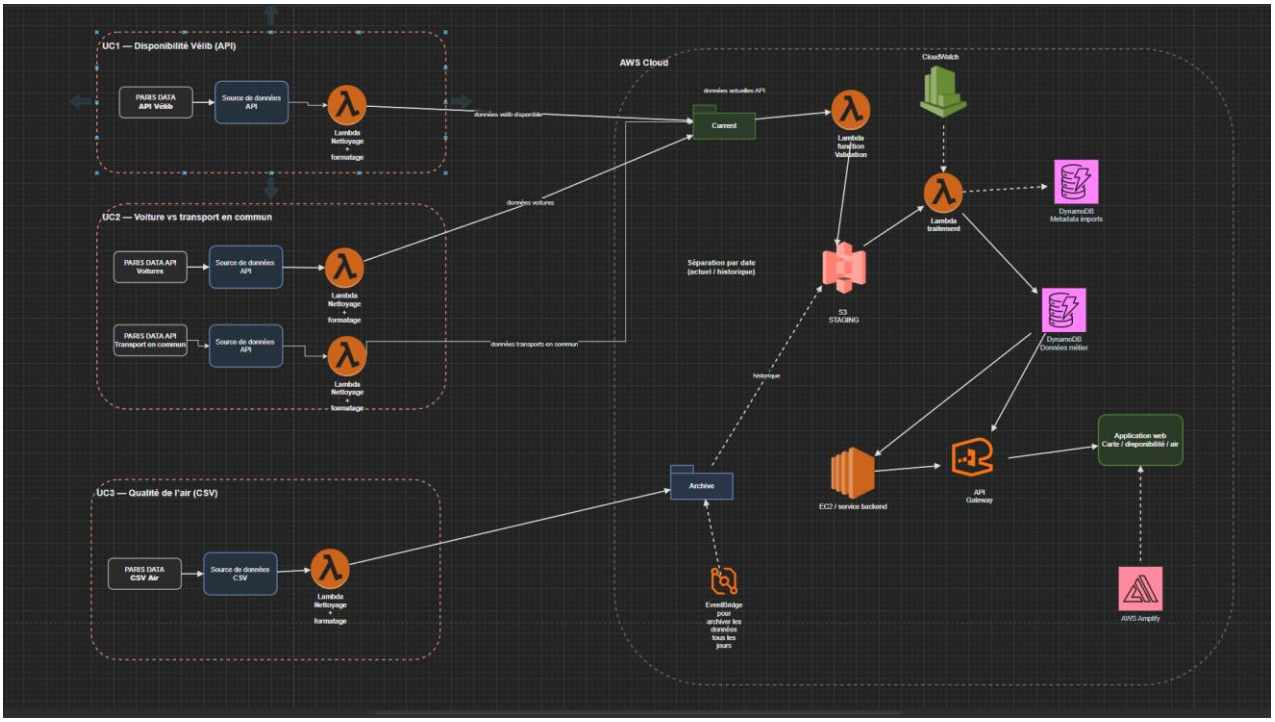

Acteur	Rôle dans le projet	Responsabilités
Data Owner	Responsable fonctionnel du domaine mobilité / qualité de l’air	Définit les règles d’usage des données, valide les accès et les exigences de qualité.
Data Steward	Référent qualité et documentation	Contrôle la cohérence des champs, maintient le dictionnaire de données, suit les anomalies.
Data Custodian	Responsable technique AWS / données	Met en œuvre le stockage, la sécurité, les sauvegardes, les politiques IAM et l’archivage.
Utilisateur	Utilisateur final ou développeur applicatif	Consulte les données selon ses droits et signale les incohérences éventuelles.
Composant	Fonction technique	Apport en gouvernance
Lambda d’ingestion	Collecte et premier formatage	Standardise l’entrée des données et applique les premiers contrôles.
S3 Current / Staging / Archive	Stockage par zone	Structure le cycle de vie, facilite la séparation des usages et l’historisation.
Lambda de validation	Contrôle qualité	Détecte les anomalies avant diffusion.
CloudWatch	Logs et supervision	Assure la traçabilité des traitements et des erreurs.

EventBridge	Planification	Automatise les tâches récurrentes comme l'archivage.
DynamoDB	Restitution métier et métadonnées	Sépare les données opérationnelles des informations de pilotage.
API Gateway + backend	Exposition applicative	Garantit que l'application n'accède qu'aux données validées.

Analyse de l'existant et idenfication des risques

L'architecture initiale repose sur une collecte via Lambda (APIs Paris Data) et un stockage S3/Dynamo DB. Bien que fonctionnelle, elle présente des limites critiques en termes de gouvernance :

- Risque de Qualité : Absence de validation à l'entrée (Schema-on-Read). Si une API change son format (ex : nb-vélos devient un texte au lieu d'un nombre), le système propage l'erreur jusqu'à l'utilisateur final.
- Sécurité et Moindre Privilège : Les rôles IAM ne sont pas assez segmentés. Une faille sur la Lambda d'ingestion pourrait potentiellement compromettre l'ensemble de la base de données.
- Déficit de Traçabilité (Data Lineage) : En cas de donnée aberrante affichée sur l'application, il est impossible de remonter à la version exacte du fichier source brut sans un historique structuré.
- Absence de Documentation Technique : Pas de dictionnaire de données permettant de garantir la cohérence des indicateurs (KPI) entre les différents développeurs.

Plan de gouvernance à définir

Stratégie de sécurité (confidentialité et intégrité)

- Gestion des Accès (IAM) : Application du principe de moindre privilège. Chaque composant possède un rôle dédié.
    - Rôle Ingestion : Écriture seule dans la zone Raw.
    - Rôle Analytics : Lecture seule dans Clean et écriture dans Gold/DynamoDB.
- Chiffrement : Activation du chiffrement au repos via AWS KMS pour tous les buckets S3 et la table DynamoDB.

Stratégie de qualité (fiabilité)

Chaque flux de données doit passer par trois filtres automatiques :

- Conformité du schéma : Vérification de la présence des colonnes obligatoires (station_id, timestamp).
- Validation des types : Conversion forcée et vérification des formats (ex : ISO 8601 pour les dates).
- Nettoyage métier : Exclusion des valeurs aberrantes (ex : vitesse de trafic > 200 km/h ou vélos négatifs)

Traçabilité et Cycle de Vie

- Historisation : Utilisation du versioning S3 et archivage automatique vers S3 Glacier après 90 jours pour réduire les coûts tout en gardant une trace légale/audit.
- Journalisation : Chaque étape de traitement émet des logs structurés dans CloudWatch avec un ID de corrélation pour suivre une donnée de l'API jusqu'à la base.

Documentation

- Dictionnaire de données : maintenu pour chaque source, décrivant les champs, types et règles de gouvernance.
- Description des pipelines : chaque Lambda est documenté avec son rôle, ses entrées, ses sorties et ses conditions d'erreur.
- Changelog : toute modification du schéma ou des règles de validation est versionnée et tracée.

Architecture cible intégrant la gouvernance

L'architecture cible organise le cycle de vie de la donnée en zones distinctes, chacune correspondant à un niveau de maturité et de contrôle. Ce modèle en couches s'inspire de l'architecture Médaillon (Bronze / Silver / Gold) et permet une séparation claire des responsabilités.

Organisation en zones de stockage

Zone	Nom	Contenu	Principe de gouvernance
Bronze	Raw / Current	Données brutes issues des API et du CSV, non modifiées.	Stockage immuable — aucune modification post-ingestion.
Silver	Staging / Clean	Données validées, typées, nettoyées. Schema Enforcement appliqué.	Seules les données conformes accèdent à cette zone.
Gold	Business / DynamoDB	Données agrégées, prêtes à la consommation applicative.	Accès restreint à l'App Role, en lecture seule.
Archive	Archive	Historique horodaté de toutes les versions passées.	Politique de rétention : 90 jours minimum.

Flux de données et mécanismes de contrôle

Le flux de données suit un chemin séquentiel et unidirectionnel entre les zones. Aucune donnée ne peut progresser d'une zone à la suivante sans avoir satisfait aux contrôles de la zone courante.

- **Ingestion :** la Lambda d'ingestion (Ingestor Role) collecte les données des API Paris Data et du CSV, puis les dépose dans la zone Bronze. Un log CloudWatch est créé à chaque exécution.
- **Validation :** la Lambda de validation (Validator Role) lit la zone Bronze, applique les contrôles de format, cohérence et intégrité. Les lignes valides sont écrites en zone Silver au format Parquet. Les lignes rejetées sont isolées dans un sous-dossier de quarantaine avec leur motif de rejet.
- **Transformation :** un traitement Lambda enrichit et agrège les données Silver pour produire les données Gold, chargées dans DynamoDB.
- **Publication :** l'API Gateway expose les données DynamoDB à l'application via l'App Role, en lecture seule.
- **Archivage :** EventBridge déclenche quotidiennement un job qui déplace les fichiers Raw vers la zone Archive avec horodatage.

Implémentation technique

Script de validation — Lambda Contrôle Qualité

Le script suivant illustre la logique de validation appliquée aux données Vélib dans la Lambda de Contrôle Qualité. Il couvre les trois niveaux définis dans le plan : contrôle de format (colonnes obligatoires), contrôle de cohérence (valeurs aberrantes) et intégrité (doublons), puis écriture en zone Clean au format Parquet. (Cf code sur git)

Dictionnaire de données

Le dictionnaire de données décrit pour chaque champ son type, sa sémantique et la règle de gouvernance associée. Il constitue la référence documentaire centrale du projet et doit être maintenu à jour à chaque évolution du schéma.

Source : API Vélib

Champ	Type	Description	Règle de gouvernance
station_id	String	Identifiant unique de la station Vélib	Clé primaire non nulle. Contrôle de doublon sur (station_id, last_reported).
num_bikes_available	Integer	Nombre total de vélos disponibles	Doit être >= 0. Toute valeur négative déclenche un rejet en quarantaine.
mechanical	Integer	Nombre de vélos mécaniques disponibles	Doit être >= 0 et <= num_bikes_available.

ebike	Integer	Nombre de vélos électriques disponibles	Doit être >= 0. mechanical + ebike doit être <= num_bikes_available.
is_installed	Boolean	État d'installation de la station	Valeurs acceptées : 1 (active) ou 0 (maintenance). Non nul.
last_reported	Timestamp	Date et heure de la dernière mise à jour	Format ISO 8601 obligatoire. Non nul. Composante de la clé de déduplication.

Source : CSV Qualité de l'air

Champ	Type	Description	Règle de gouvernance
segment_id	String	Identifiant du segment de mesure	Non nul. Clé de déduplication avec date_mesure.
no2_concentration	Float	Concentration en dioxyde d'azote (µg/m³)	Doit être >= 0. Valeur maximale plausible : 500 µg/m³.
pm25	Float	Particules fines PM2.5 (µg/m³)	Doit être >= 0. Valeur maximale plausible : 300 µg/m³.
date_mesure	Date	Date de la mesure	Format YYYY-MM-DD obligatoire. Non nulle.

Justification des choix techniques

Chaque service AWS retenu dans l'architecture a été sélectionné en cohérence avec les principes de gouvernance définis. Le tableau suivant synthétise les arbitrages réalisés

Service	Rôle	Justification
Amazon S3 (multi-zones)	Stockage structuré	Séparation claire du cycle de vie (Bronze/Silver/Gold) et politique de rétention différenciée par zone. Format Parquet pour la compression et la compatibilité analytique.
AWS Lambda	Traitement serverless	Exécution à la demande, sans serveur à gérer. Chaque Lambda porte une responsabilité unique, ce qui facilite l'audit et le débogage.
AWS IAM	Contrôle des accès	Granularité fine des permissions par rôle et par ressource. Application native du Principe du Moindre Privilège sans

		surcoût opérationnel.
AWS KMS	Chiffrement au repos	Gestion centralisée des clés de chiffrement avec séparation par zone pour limiter la surface d'exposition.
Amazon CloudWatch	Observabilité	Centralisation des logs structurés de chaque Lambda. Alarms configurables pour la détection proactive des anomalies. Constitue le lineage technique de la solution.
Amazon EventBridge	Orchestration	Planification des jobs d'archivage sans dépendance applicative. Découplage entre le pipeline temps réel et la gestion de l'historique.
Amazon DynamoDB	Restitution métier	Latence faible pour les requêtes applicatives. Accès restreint à l'App Role en lecture seule.

Conclusion

La mise en place de ce plan de gouvernance transforme le projet Smart City d'un pipeline technique fonctionnel en une solution alignée sur les bonnes pratiques professionnelles de la gestion des données dans le cloud.

En distinguant clairement les zones de stockage par niveau de maturité, en appliquant le Principe du Moindre Privilège sur chaque composant, en automatisant les contrôles qualité et en produisant des logs de traçabilité structurés, le système répond aux trois risques identifiés dans le diagnostic initial : la corruption silencieuse des données, les accès permissifs et l'absence de lineage.

Cette architecture constitue une base évolutive sur laquelle des mécanismes plus avancés pourront être greffés : gestion automatisée des métadonnées, classification des données, ou intégration d'un outil de Data Catalog. L'objectif était de poser un cadre cohérent, justifié et opérationnel.